Міністерство освіти і науки України
Національний університет “Львівська політехніка”
Інститут комп’ютерних наук та інформаційних технологій

Кафедра САПР

Лабораторна робота №1

з дисципліни: “Застосування систем штучного інтелекту у технологічних рішеннях”

на тему:

“ Огляд інструментів для роботи з AI: налаштування середовища (Python, TensorFlow, PyTorch, Google Colab). Створення базового класифікатора рукописних цифр MNIST для прикладу в навчанні”

Варіант №3

Виконав:
ст. групи ПП-44
Верещак Б. О.
Прийняв:
доц. Левкович М.В.

Львів - 2025

Мета роботи

Налаштувати робоче середовище для розробки моделей ШІ (Python + бібліотеки, Google Colab) та створити базовий класифікатор рукописних цифр MNIST як референтний приклад, що демонструє повний цикл: підготовка даних → побудова простої нейромережі (MLP або CNN) у TensorFlow/Keras (або PyTorch) → навчання й оцінювання якості (accuracy, confusion matrix) → збереження моделі та відтворюваний запуск.

Індивідуальне завдання

Для виконання роботи використовуйте надані приклади коду. Порівняйте отримане значення точності для моделі CNN з точністю простої повнозв'язної мережі. Залежно від вашого номера у списку групи, виконайте додаткові індивідуальні вимоги згідно з таблицею:

№ варіанта	Batch size	Кількість епох	Оптимізатор	Додаткове завдання
3	128	15	RMSprop	Побудувати confusion matrix

Хід роботи

1. Налаштування середовища та завантаження даних

Перед початком виконання лабораторної роботи потрібно підготувати середовище розробки, я обрав google collab, і імпортувати потрібні модулі та датасети, в нашому випадку MNIST для класифікації рукописних цифр.

```
import tensorflow as tf
import matplotlib.pyplot as plt
import numpy as np
import random

mnist = tf.keras.datasets.mnist
(train_images, train_labels), (test_images, test_labels) = mnist.load_data()
train_images = (np.expand_dims(train_images, axis= 1)/255.).astype(np.float)
train_labels = (train_labels).astype(np.int64)
test_images = (np.expand_dims(test_images, axis=-1)/255.).astype(np.float32)
test_labels = (test_labels).astype(np.int64)
```

2. Побудова повнозв'язної нейронної мережі

На цьому кроці нам потрібно створити саму повнозв'язну нейронну мережу. Спочатку ініціалізуємо саму модель

```
def build_fc_model():
  fc_model = tf.keras.Sequential([
    tf.keras.layers.Flatten(input_shape=(28, 28, 1)),
    tf.keras.layers.Dense(128, activation="relu"),
```

```
    tf.keras.layers.Dense(10, activation="softmax")
  ])
  return fc_model

model = build_fc_model()
```

Тепер потрібно скомпілювати модель та надати її дані для навчання. Згідно варіанту використовуємо оптимізатор RMSprop разом з розміром пакета (batch_size) 128 та кількістю епох (epochs) 15.

```
model.compile(
    optimizer=tf.keras.optimizers.RMSprop(learning_rate=0.1),
    loss="sparse_categorical_crossentropy",
    metrics=["accuracy"]
)

BATCH_SIZE = 128
EPOCHS = 15

history = model.fit(
 train_images,train_labels,
 batch_size=BATCH_SIZE,
 epochs=EPOCHS
)
test_loss, test_acc = model.evaluate(test_images, test_labels, verbose=2)

print("Точність на навчальних даних:", history.history["accuracy"][-1], "\n
Значення втрати", history.history['loss'][-1])
print("Точність на тестових даних:", test_acc, "\n Значення втрати",
test_loss)
```

В результаті ми отримуємо точність і похибку моделі. З результатів видно що великої різниці між точністю на навчальних, чи тестових даних становить близько 1.1%, але видно що значення втрати більше з тестовими даними.

```
Точність на навчальних даних: 0.9927833080291748
Значення втрати: 0.03181539848446846
Точність на тестових даних: 0.979200005531311
Значення втрати: 0.20555131137371063
```

3. Побудова згорткової нейронної мережі

З результатів минулої мережі видно, що повнозв’язна мережа не ідеально справляються з розпізнаванням цифр, тому переважно використовують згорткові нейронні мереж, які довели свою ефективність у розв’язанні завдань комп’ютерного зору. Спочатку ініціалізуємо архітектуру

```
def build_cnn_model():
  cnn_model = tf.keras.Sequential([
    tf.keras.layers.Conv2D(filters=24, kernel_size=(3,3),
activation=tf.nn.relu),
    tf.keras.layers.MaxPool2D(pool_size=(2,2)),
```

```
    tf.keras.layers.Conv2D(filters=36, kernel_size=(3,3),
activation=tf.nn.relu),
    tf.keras.layers.MaxPool2D(pool_size=(2,2)),
    tf.keras.layers.Flatten(),
    tf.keras.layers.Dense(128, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)
  ])
  return cnn_model
cnn_model = build_cnn_model()
```

Тепер давайте скомпілюємо модель за нашим варіантом

```
cnn_model.compile(
  optimizer=tf.keras.optimizers.RMSprop(learning_rate=1e-3),
  loss="sparse_categorical_crossentropy",
  metrics=["accuracy"]
)

history_cnn = cnn_model.fit(
  train_images,
  train_labels,
  batch_size=BATCH_SIZE,
  epochs=EPOCHS
)

test_loss, test_acc = cnn_model.evaluate(test_images, test_labels,
verbose=2)

print("Точність на навчальних даних:", history_cnn.history["accuracy"][-1],
"\nЗначення втрати:", history_cnn.history['loss'][-1])
print("Точність на тестових даних:", test_acc, "\nЗначення втрати:",
test_loss)
```

Тут результати на навчальних даних практично ідеальні, так як модель розроблена спеціально під такий тип розпізнавання

```
Точність на навчальних даних: 0.9990166425704956
Значення втрати: 0.003010542131960392
Точність на тестових даних: 0.9902999997138977
Значення втрати: 0.043695155531167984
```

4. Порівняння моделей

Для кращого порівняння використаних мереж, давайте спробуємо порівняти результати між ними

Модель	Точність навч.	Втрата навч.	Точність тест.	Втрата тест.	Параметри навчання
FCN	99.28%	3.18%	97.92%	20.56%	batch_size=128, epochs=15, RMSprop
CNN	99.90%	0.30%	99.03%	4.37%	batch_size=128, epochs=15, RMSprop

Результати	+0.62%	-2.88%	+1.05	-16.19	CNN ефективніша

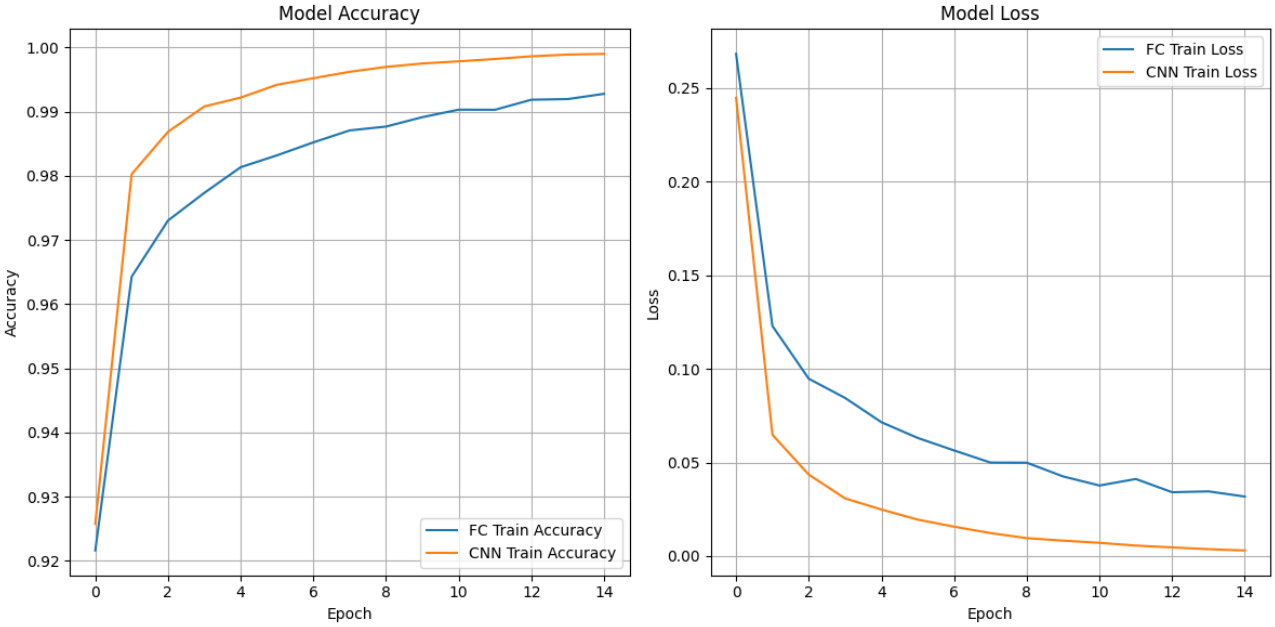

Графіки навчання моделей показують: CNN швидше досягає високої точності, має менше перенавчання та згорткові шари краще виділяють просторові ознаки.

5. Індивідуальне завдання. Confusion matrix

Для виконання цього завдання я використовував готову бібліотеку з sklearn, щоб згенерувати та відобразити матрицю змішування. З результатів видно, що вертикально розташовані правильні мітки, а по горизонталі, ті які модель передбачила. Тому ті результати, що на діагоналі показують кількість правильно вгаданих цифр.

```
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay

predictions_fcnn = model.predict(test_images)
predictions_cnn = cnn_model.predict(test_images)

predicted_labels_fcnn = np.argmax(predictions_fcnn, axis=1)
predicted_labels_cnn = np.argmax(predictions_cnn, axis=1)

cm_fcnn = confusion_matrix(test_labels, predicted_labels_fcnn)
cm_cnn = confusion_matrix(test_labels, predicted_labels_cnn)

disp_fcnn = ConfusionMatrixDisplay(confusion_matrix=cm_fcnn,
display_labels=range(10))
disp_fcnn.plot(cmap=plt.cm.Blues, values_format='d')
plt.title("Confusion Matrix for FCNN")
plt.show()

disp_cnn = ConfusionMatrixDisplay(confusion_matrix=cm_cnn,
display_labels=range(10))
disp_cnn.plot(cmap=plt.cm.Blues, values_format='d')
plt.title("Confusion Matrix for CNN")
plt.show()
```

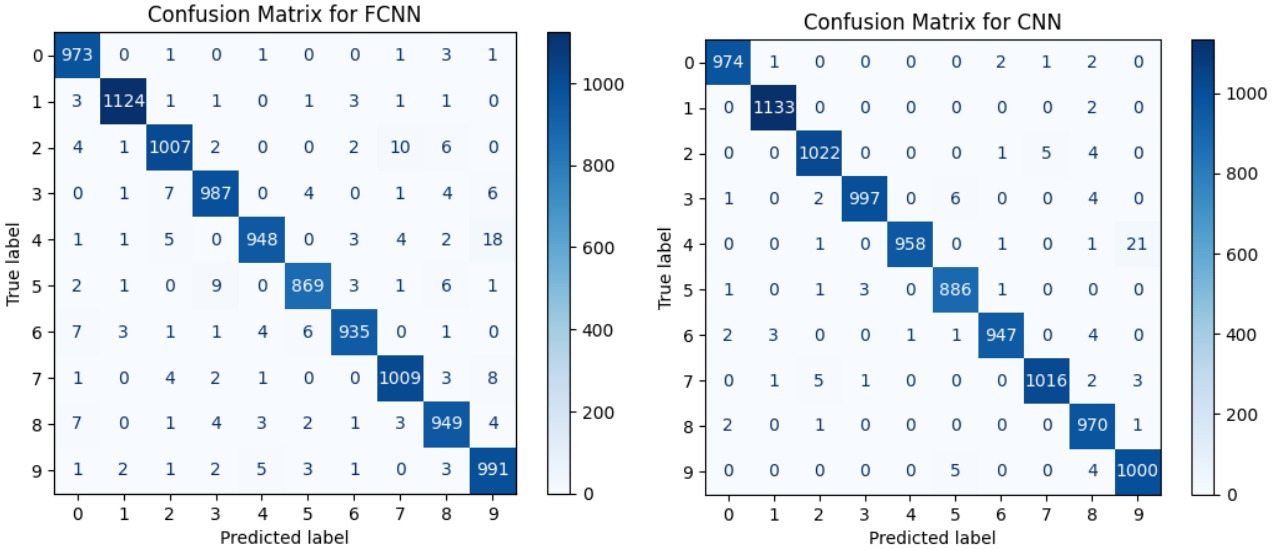

Висновки

У ході виконання лабораторної роботи було налаштовано робоче середовище TensorFlow/Keras та проведено порівняльний аналіз нейронних мереж: повнозв'язна мережа показала точність на тестових даних у 97.92%, тоді як згорткова досягла 99.02%, що демонструє її перевагу у 0.62% для задач комп'ютерного зору. Для варіанту 3 з параметрами batch size=128, epochs=15 та оптимізатором RMSprop було досягнуто ефективного навчання без значного перенавчання, а індивідуальне завдання з confusion matrix візуалізацією підтвердило, що основні помилки класифікації виникають між візуально подібними цифрами (4 і 9, 3 і 5), що є типовим для набору даних MNIST.